



SOUTENANCE PROJET 11

Fruits! — Chaîne de traitement Big Data

Parcours AI Engineer - Preprocessing, transfer learning et réduction de dimension avec PySpark — vers une architecture Big Data sur AWS

Stéphanie Duhem - Juillet 2026



00. CONTEXTE & OBJECTIFS

LE CONTEXTE

- **Start-up AgriTech** : développement de robots cueilleurs intelligents pour la préservation de la biodiversité
- **Visibilité** : application mobile de reconnaissance de fruits › sensibilisation à la biodiversité et amorce d'architecture Big Data
- **Mon rôle** : Pipeline de featurisation en amont du futur modèle de classification et adaptée Big Data + Cloud

OBJECTIFS

- › Reprise de l'existant : Chaîne de traitement pour l'app Fruits! réalisé en optique Cloud 
- › Consolidation : Finaliser et optimiser la chaîne de traitement dans une optique Big Data 
- › Preuve de concept : Démontrer la faisabilité d'un passage à l'échelle sur une architecture Big Data + Cloud 



CONTRAINTES TECHNIQUES

- **Volume** : Jeu de données en croissance (90 483 images aujourd'hui) 
- **RGPD** : Traitement et stockage sur territoire européen 
- **Calcul distribué** : PySpark 
- **Budget** : Ressources Cloud maîtrisées 

01. DATASET – Fruits-360 (Kaggle)

LE DATASET COMPLET

- **Volume** : 90 483 images (train + test) - 131 classes
- **Format des images** : 100×100 pixels - RGB - JPEG

```
fruits-360/  
├── Training/      (131 classes)  
│   └── Apricot/0_100.jpg, 1_100.jpg, ...  
└── Test/          (131 classes, même structure)
```

Dimensions du dataset à adapter à l'usage

(Mise en place de la pipeline sans training)

» **Méthode** : Échantillonnage systématique > diversité représentative



```
data/sample/  
├── Apricot/30_100.jpg, 31_100.jpg, ...  
├── Cherry/...  
└── ... (10 classes au total, pas de split  
Training/Test)
```


ÉCHANTILLON DE TRAVAIL

Source : train (prepare_sample.py)


300 images - 10 classes

- Apple Braeburn 
- Apricot 
- Cherry 
- Dates 
- Guava 
- Mango Red 
- Papaya 
- Pear Williams 
- Plum 
- Strawberry 

02-A. Spark - Moteur de calcul distribué en 4 acteurs



2-B. PySpark - Chaîne de traitement pour calcul distribué




Pourquoi le broadcast des poids du modèle ?

`feature_model` est un objet complexe (graphe TensorFlow), impossible à sérialiser efficacement vers chaque processus à chaque tâche.

» **Solution** : chaque processus reconstruit l'architecture localement et reçoit uniquement les poids déjà entraînés via broadcast

2-C. PySpark - Exécution en local



	path	label
0	file:/Users/stephanieduhem/Documents/_DIPLOMES...	Strawberry Wedge
1	file:/Users/stephanieduhem/Documents/_DIPLOMES...	Strawberry Wedge
2	file:/Users/stephanieduhem/Documents/_DIPLOMES...	Strawberry Wedge
3	file:/Users/stephanieduhem/Documents/_DIPLOMES...	Guava
4	file:/Users/stephanieduhem/Documents/_DIPLOMES...	Guava

	pca_features
0	[-5.287437330475509, 0.9938178276457581, 20.97...
1	[-2.5941090307530086, 0.32458644373422624, 19....
2	[-5.224705457906081, 1.0375195715629957, 19.60...
3	[-4.891880303929059, -7.5702791631416995, 4.84...
4	[-6.323576325095195, -8.627868361164134, 3.570...

Dimension du vecteur PCA : (53,)

Réduction de dimension : 1280 -> 53 (95.9% de moins)

03-A. AWS - Les briques choisies et leur rôle

EMRFS (EMR File System)

Lecture : `spark.read...load("s3://...")` & Écriture : `df.write.parquet("s3://...")`

Bucket S3

Stockage indépendant des données
Région eu-north-1 (Stockholm, Suède) - Maintenu (stateless)

Données

» Images sources et des résultats (matrice PCA)

Vigilance RGPD

» Point de vigilance identifié : le bucket S3 du code existant n'était pas en région UE
» S3 et EMR doivent être dans la même région pour rester cohérents et éviter des coûts/latences de transfert inter-région.

EMR

Cluster Spark managé, Elastic MapReduce
Région eu-north-1 (Stockholm, Suède) - Résilié en fin de tâche

Master Node > Primary Node = 1 Instance EC2

» Héberge le driver program **Spark** et le gestionnaire de ressources (CPU, mémoire) **YARN**

Worker node > Core Node & Task Node

» Héberge les conteneurs YARN, chacun hébergeant un executor
» Continuité avec le code existant

IAM

Gestion des identités et permissions, Identity and Access Management

Utilisateur IAM (p11-admin) » identité permanente, accès au bucket via la console

Rôle IAM (EMR_EC2_DefaultRole) » attachée à une Policy IAM, liste les actions autorisées sur un bucket, persistant




Instance profile » rôle IAM rattaché à l'instance EC2 du cluster, récupère la Policy IAM, résilié en fin de tâche

Sécurité » Aucune permission n'est accordée par défaut entre deux services AWS : sans rôle IAM explicite, chaque tentative de lecture S3 depuis EMR échouerait (Access Denied).

03-B. AWS - Déploiement

DÉPLOIEMENT INITIÉ


- » **Compte AWS** créé, budget avec alertes (50/80/100%)
- » **Utilisateur IAM** dédié (hors compte root)
- » **Bucket S3** en région **UE**, chiffré, accès public bloqué
- » **Données** de test uploadées sur S3
- » **Portabilité vers EMR** : Script de bootstrap EMR + notebook cloud adaptés (chemins S3), prêts à l'usage



03-B. AWS - Blocage plateforme

BLOCAGE TECHNIQUE AWS

- Le compte est placé sur un "Free account plan" avec accès restreint : EMR reste bloqué tant que la vérification n'est pas complète.
- La vérification n'aboutit pas > **contrainte de la plateforme.**



03-B. BILAN & PERSPECTIVES

OBJECTIFS ATTEINTS

- » **Présentation de l'architecture Spark** et de sa portabilité vers EMR
- » Ajout des 2 briques demandées : **broadcast des poids & PCA**
- » **Pipeline PySpark** locale complète, testée et validée de bout en bout
- » Démarches de mise en oeuvre de l'environnement **Big Data**
- » **Présentation & mise en place de l'infrastructure AWS** (compte, IAM, S3, RGPD, bootstrap, portabilité EMR avec notebook cloud)
- » **Consolidation** des travaux existants

LIMITES & PROCHAINES ÉTAPES

- Finaliser le déploiement EMR dès la levée du blocage AWS
- Revalider le k de la PCA sur le jeu de données complet (131 classes)
- Recalculer le partitionnement selon les executors réels du cluster



Merci de votre attention.

